



دانشگاه تهران  
دانشکده مهندسی برق و  
کامپیوتر




درس یادگیری ماشین  
تمرین سوم

نام و نام خانوادگی	میلاد محمدی
شماره دانشجویی	810100462
تاریخ ارسال گزارش	1401/09/11


## سوال اول


### قسمت الف)

در شکل A دو کلاس داریم و لایه خروجی دارای دو نورون خواهد بود. با توجه به اینکه داده‌ها در دو بعد هستند، لایه ورودی نیز دارای دو نورون خواهد بود. نیازی به لایه پنهان نیست چون با استفاده از دو خط متقاطع کلاس‌ها قابل جداسازی می‌باشند. در صورتی لایه پنهان نیاز بود که بخواهیم با استفاده از یک خط خمیده کلاس‌ها را از هم جدا کنیم ولی ساده‌ترین مدل مدنظر ماست.



در شکل B سه کلاس داریم و لایه خروجی دارای سه نورون خواهد بود. با توجه به اینکه داده‌ها در دو بعد هستند، لایه ورودی نیز دارای دو نورون خواهد بود. نیازی به لایه پنهان نیست چون با استفاده از دو خط متقاطع کلاس‌ها قابل جداسازی می‌باشند و ساده‌ترین مدل مدنظر ماست.






$$(0, 0): (0 * -0.1) + (0 * -0.1) = 0 > -0.15 \rightarrow Y = 1$$

$$(0, 1): (0 * -0.1) + (1 * -0.1) = -0.1 > -0.15 \rightarrow Y = 1$$

$$(1, 0): (1 * -0.1) + (0 * -0.1) = -0.1 > -0.15 \rightarrow Y = 1$$

$$(1, 1): (1 * -0.1) + (1 * -0.1) = -0.2 < -0.15 \rightarrow Y = 0$$

با توجه به خروجی‌ها، گیت NAND می‌باشد.



$$(0, 0): (0 * -0.1) + (0 * -0.1) = 0 > -0.05 \rightarrow Y = 1$$


$$(0, 1): (0 * -0.1) + (1 * -0.1) = -0.1 < -0.05 \rightarrow Y = 0$$

$$(1, 0): (1 * -0.1) + (0 * -0.1) = -0.1 < -0.05 \rightarrow Y = 0$$

$$(1, 1): (1 * -0.1) + (1 * -0.1) = -0.2 < -0.05 \rightarrow Y = 0$$

با توجه به خروجی‌ها، گیت NOR می‌باشد.

قسمت ج) گیت XNOR با استفاده از ترکیب سه گیت AND، NOR و OR پیاده‌سازی می‌شود. در لایه‌های پنهان و لایه خروجی  $\theta = 0$  است.



$(0, 0)$ : AND:  $(0 * 1) + (0 * 1) - 1 = -1 < 0 \rightarrow 0$

NOR:  $(0 * -1) + (0 * -1) + 1 = 1 > 0 \rightarrow 1$

OR:  $(0 * 2) + (1 * 2) - 1 = 1 > 0 \rightarrow Y = 1$

---

$(0, 1), (1, 0)$ : AND:  $(0 * 1) + (1 * 1) - 1 = 0 \leq 0 \rightarrow 0$

NOR:  $(0 * -1) + (1 * -1) + 1 = 0 \leq 0 \rightarrow 0$


OR:  $(0 * 2) + (0 * 2) - 1 = -1 < 0 \rightarrow Y = 0$

---

$(1, 1)$ : AND:  $(1 * 1) + (1 * 1) - 1 = 1 > 0 \rightarrow 1$

NOR:  $(1 * -1) + (1 * -1) + 1 = -1 < 0 \rightarrow 0$

OR:  $(1 * 2) + (0 * 2) - 1 = 1 > 0 \rightarrow Y = 1$



ابتدا خروجی را حساب می‌کنیم. حساب خطا را به دست آورده و پس انتشار انجام می‌دهیم تا وزن‌ها به‌روز شوند.

$$f(Z_1): W_{01} * 1 + W_{11} * X_1 + W_{21} * X_2 = (0.4 * 1) + (0.7 * 1) + 0 = f(1.1) = 0.75$$

$$f(Z_2): W_{02} * 1 + W_{12} * X_1 + W_{22} * X_2 = (0.6 * 1) + (-0.4 * 1) + 0 = f(0.2) = 0.53$$

$$f(Y): V_0 * 1 + V_1 * X_1 + V_2 * X_2 = (-0.3 * 1) + (0.75 * 0.5) + (0.1 * 0.53) = f(0.2) = 0.128$$

$$error = 0.5 * (0.128 - 0)^2 = 0.008$$

$$\sigma_Y = 1 * error = 1 * 0.008 = 0.008$$

$$\sigma_{Z_1} = f(z_1)(1 - f(z_1)) * V_1 * \sigma_Y = 0.75 * 0.25 * 0.5 * 0.008 = 0.00075$$

$$\sigma_{Z_2} = f(z_2)(1 - f(z_2)) * V_2 * \sigma_Y = 0.53 * 0.47 * 0.1 * 0.008 = 0.0001$$

$$W_{ji}(new) = \alpha \delta_j f(z_j), \quad W_{ji}(new) = W_{ji}(old) + W_{ji}(new)$$

$$\Delta V_0 = 0.2 * 0.008 * 1 = 0.0016 \rightarrow V_0(new) = -0.3 + 0.0016 = -0.2984$$

$$\Delta V_1 = 0.2 * 0.008 * 0.75 = 0.0012 \rightarrow V_1(new) = 0.5 + 0.0012 = 0.5012$$

$$\Delta V_2 = 0.2 * 0.008 * 0.53 = 0.0008 \rightarrow V_2(new) = 0.1 + 0.0008 = 0.1008$$

$$\Delta W_{11} = 0.2 * 0.00075 * 1 = 0.0001 \rightarrow W_{11}(new) = 0.7 + 0.0001 = 0.7001$$

$$\Delta W_{21} = 0.2 * 0.00075 * 0 = 0 \rightarrow W_{21}(new) = -0.2$$

$$\Delta W_{12} = 0.2 * 0.0001 * 1 = 0.00002 \rightarrow W_{12}(new) = -0.4 + 0.00002 = -0.39$$

$$\Delta W_{22} = 0.2 * 0.0001 * 0 = 0 \rightarrow W_{22}(new) = 0.3$$


$$\Delta W_{01} = 0.2 * 0.00075 * 1 = 0.0001 \rightarrow W_{01}(new) = 0.4 + 0.0001 = 0.4001$$

$$\Delta W_{02} = 0.2 * 0.0001 * 1 = 0.00002 \rightarrow W_{02}(new) = 0.6 + 0.00002 = 0.60002$$

## سوال سوم

$$H(y) = -\frac{4}{10} * \log \frac{4}{10} - \frac{6}{10} * \log \frac{6}{10} = 0.29$$

ویژگی رنگ:



$$P(y = + | \text{آبی}) = 1/4$$


$$P(y = + | \text{سبز}) = 0$$

$$P(y = + | \text{قرمز}) = 3/4$$

$$H(y | \text{رنگ}) = \frac{4}{10} H\left(\frac{1}{4}\right) + \frac{2}{10} H(0) + \frac{4}{10} H\left(\frac{3}{4}\right) = \frac{8}{10} \left(-\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4}\right)$$

$$I(y; \text{رنگ}) = H(y) - H(y | \text{رنگ}) = 0.29 - 0.19 = 0.1$$

ویژگی جنس:




$$P(y = + | \text{پشمنی}) = 1/6$$

$$P(y = + | \text{نخی}) = 3/4$$

$$H(y | \text{جنس}) = \frac{6}{10} H\left(\frac{1}{6}\right) + \frac{4}{10} H\left(\frac{3}{4}\right) = \frac{4}{10} \left(-\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4}\right) + \frac{6}{10} \left(-\frac{1}{6} \log \frac{1}{6} - \frac{5}{6} \log \frac{5}{6}\right)$$

$$I(y; \text{جنس}) = H(y) - H(y | \text{جنس}) = 0.29 - 0.20 = 0.09$$

## ویژگی قیمت:




$$P(y = + | \text{ارزان}) = 1/2$$

$$P(y = + | \text{گران}) = 1/3$$

$$H(y | \text{قیمت}) = \frac{6}{10} H\left(\frac{1}{3}\right) + \frac{4}{10} H\left(\frac{1}{2}\right) = \frac{4}{10} \left(-\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2}\right) + \frac{6}{10} \left(-\frac{1}{3} \log \frac{1}{3} - \frac{2}{3} \log \frac{2}{3}\right)$$

$$I(y; \text{قیمت}) = H(y) - H(y | \text{قیمت}) = 0.28 - 0.28 = 0$$

با استفاده از درخت نیز بدیهی بود که ویژگی رنگ بهترین است.



با استفاده از درخت بالا پیش‌بینی‌ها به این صورت انجام می‌شود که برچسب رنگ آبی منفی (1 غلط)، رنگ سبز منفی و رنگ قرمز مثبت (1 غلط) خواهد بود. جدول زیر با توجه به ویژگی رنگ ساخته شده ولی صحت و دقت با استفاده از جنس نیز همین مقادیر خواهد بود.

Pred \ Real	Pred	
	+	-
+	3	1
-	1	5

$$Recall = \frac{TP}{P} = \frac{3}{4}, Precision = \frac{TP}{TP+FP} = \frac{3}{4}, Accuracy = \frac{TP+TN}{n} = \frac{3+5}{10} = 0.8$$

## سوال چهارم

قسمت الف)

**مورد اول:** زمانی که  $x$  کوچکتر از 0 است:  $x - x_i < 0$  و در نتیجه  $P_n(x)$  برابر صفر خواهد بود. پس میانگین نیز برابر صفر خواهد بود.

**مورد دوم:** زمانی که  $0 \leq x \leq a$ :

$$\begin{aligned} P_n^-(x) &= E[P_n(x)] = \frac{1}{n} \sum_{i=1}^n E\left[\frac{1}{h_n} * e^{-\frac{x-x_i}{h_n}}\right] = \int_0^x \frac{1}{ah_n} e^{-\frac{x-t}{h_n}} dt \\ &= \frac{1}{a} e^{-\frac{x}{h_n}} * \left(e^{\frac{x}{h_n}} - 1\right) = \frac{1}{a} (1 - e^{-\frac{x}{h_n}}) \end{aligned}$$

**مورد سوم:** با توجه به اینکه  $p(x) \sim U(0, a)$  تمامی  $x_i$  ها در بازه 0 تا  $a$  قرار خواهند داشت.

$$V_n = \int e^{\frac{x-x_i}{h_n}} = h_n$$

$$x \geq a \rightarrow x - x_i \geq 0$$

$$P_n(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{v_n} * \varphi\left(\frac{x-x_i}{h_n}\right) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h_n} * e^{-\frac{x-x_i}{h_n}}$$

$$\begin{aligned} P_n^-(x) &= E[P_n(x)] = \frac{1}{n} \sum_{i=1}^n E\left[\frac{1}{h_n} * e^{-\frac{x-x_i}{h_n}}\right] = \int_0^a \frac{1}{ah_n} e^{-\frac{x-t}{h_n}} dt \\ &= \frac{1}{a} e^{-\frac{x}{h_n}} * \left(e^{\frac{a}{h_n}} - 1\right) \end{aligned}$$



قسمت ب) با توجه به  $p(x) \sim U(0, a)$ :

$$p(x) = \begin{cases} \frac{1}{a}, & 0 \leq x \leq a \\ 0, & otherwise \end{cases}$$

بایاس از رابطه زیر به دست می‌آید:

$$p(x) - P_n^-(x) = \begin{cases} 0 & x < 0 \\ \frac{1}{a} * e^{\left(-\frac{x}{h_n}\right)} & 0 \leq x \leq a \\ -\frac{1}{a} e^{-\frac{x}{h_n}} * \left(e^{\frac{a}{h_n}} - 1\right) & x > a \end{cases}$$

برای اینکه اندازه‌ی بایاس تخمین پارزن، در نود و نه درصد از طول بازه‌ی 0 تا a کمتر یک درصد باشد:

$$\frac{p(x) - P_n^-(x)}{p(x)} \leq 0.01 \rightarrow \frac{\frac{1}{a} * e^{\left(-\frac{x}{h_n}\right)}}{\frac{1}{a}} \leq 0.01 \rightarrow h_n \leq \frac{(0.01 * a)}{\ln 100}$$

قسمت الف)

احتمال پیشین دو کلاس برابر است. احتمال متوسط خطا برای  $n$  نقطه به صورت زیر است:

$$\begin{aligned} p_n(e) &= p(x \in \omega_1, y \rightarrow \omega_2) + p(x \in \omega_2, y \rightarrow \omega_1) = 2p(x \in \omega_1, y \rightarrow \omega_2) \\ &= 2p(\omega_1) * p_r(\text{label of } \omega_1 \text{ for fewer than } \frac{k-1}{2} \text{ points and rest} \rightarrow \omega_2) \\ &= 2 * \frac{1}{2} \sum_{j=0}^{\frac{k-1}{2}} \binom{n}{j} \frac{1}{2^j} \frac{1}{2^{n-j}} = \frac{1}{2^n} \sum_{j=0}^{\frac{k-1}{2}} \binom{n}{j} \end{aligned}$$

قسمت ب) مقدار خطا برای حالت  $k = 1$  برابر  $\frac{1}{2^n}$  است در حالی که خطا برای حالت  $k > 1$ ،  
 $\frac{1}{2^n} \sum_{j=0}^{\frac{k-1}{2}} \binom{n}{j}$  می باشد که بدیهی است برای حالت  $k = 1$  کمتر است.

قسمت ج)

$$p_n(e) = \frac{1}{2^n} \sum_{j=0}^{\frac{k-1}{2}} \binom{n}{j} = p\left(B\left(n, \frac{1}{2}\right) \leq \frac{k-1}{2}\right) = p(Y_1 + Y_2 + \dots + Y_n \leq \frac{k-1}{2})$$

تمامی  $Y_i$  ها مستقل از هم هستند و  $B$  توزیع  $Binomial$  می باشد و در این سوال  $\frac{1}{2}$

$$p_n(e) = p\left(Y_1 + Y_2 + \dots + Y_n \leq \frac{\frac{a}{\sqrt{n}} - 1}{2}\right) = p(Y_1 + Y_2 + \dots + Y_n \leq 0)$$

بنابراین با افزایش  $n$  به سمت بی نهایت، میزان خطا به صفر نزدیک خواهد شد.

# 1 Question 6

```
[1]: from keras.datasets import cifar10
      from sklearn.model_selection import train_test_split
      import random
      import matplotlib.pyplot as plt
      import numpy as np
      import tensorflow as tf
      from tensorflow import keras
      from tensorflow.keras import layers
      from sklearn.metrics import plot_confusion_matrix
      from keras.layers import BatchNormalization
      import pandas as pd
      from sklearn.metrics import confusion_matrix, precision_recall_fscore_support
      import keras.utils.vis_utils
      from importlib import reload
      import pydot
      reload(keras.utils.vis_utils)
      keras.utils.vis_utils.pydot = pydot
      from tensorflow.keras.utils import to_categorical
      from tabulate import tabulate

[2]: (X_train_full, y_train_full), (X_test, y_test) = cifar10.load_data()

Downloading data from https://www.cs.toronto.edu/~kriz/cifar-10-python.tar.gz
170498071/170498071 [=====] - 14s 0us/step

[3]: X_train_normal = X_train_full/255
      X_test_normal = X_test/255

[4]: X_train, X_val, y_train, y_val = train_test_split(X_train_normal, y_train_full,
      ➔test_size=0.15, random_state = 20)

[5]: y_train_onehot = to_categorical(y_train, 10)
      y_test_onehot = to_categorical(y_test, 10)
      y_val_onehot = to_categorical(y_val, 10)

[6]: np.random.seed(0)
      tf.random.set_seed(0)

[7]: def plot(x):

      loss = model_history.history.copy()
      loss.pop('accuracy')
      loss.pop('val_accuracy')
      acc = model_history.history.copy()
      acc.pop('loss')
      acc.pop('val_loss')

      pd.DataFrame(loss).plot(figsize=(8,5))
      plt.grid(True)
      plt.show()

      pd.DataFrame(acc).plot(figsize=(8,5))
      plt.grid(True)
      plt.ylim(0,1)
      plt.show()
```

```
[8]: model = keras.models.Sequential()
model.add(layers.Conv2D(32, (3, 3), activation='relu',
    ↳kernel_initializer='he_uniform', padding='same', input_shape=(32, 32, 3)))
model.add(BatchNormalization())
model.add(layers.Conv2D(32, (3, 3), activation='relu',
    ↳kernel_initializer='he_uniform', padding='same'))
model.add(BatchNormalization())
model.add(layers.MaxPooling2D((2, 2)))
model.add(layers.Dropout(0.2))
model.add(layers.Conv2D(64, (3, 3), activation='relu',
    ↳kernel_initializer='he_uniform', padding='same'))
model.add(BatchNormalization())
model.add(layers.Conv2D(64, (3, 3), activation='relu',
    ↳kernel_initializer='he_uniform', padding='same'))
model.add(BatchNormalization())
model.add(layers.MaxPooling2D((2, 2)))
model.add(layers.Dropout(0.3))
model.add(layers.Conv2D(128, (3, 3), activation='relu',
    ↳kernel_initializer='he_uniform', padding='same'))
model.add(BatchNormalization())
model.add(layers.Conv2D(128, (3, 3), activation='relu',
    ↳kernel_initializer='he_uniform', padding='same'))
model.add(BatchNormalization())
model.add(layers.MaxPooling2D((2, 2)))
model.add(layers.Dropout(0.4))
model.add(layers.Flatten())
model.add(layers.Dense(128, activation='relu', kernel_initializer='he_uniform'))
model.add(BatchNormalization())
model.add(layers.Dropout(0.5))
model.add(layers.Dense(10, activation='softmax'))
opt = tf.keras.optimizers.SGD(lr=0.001, momentum=0.9)
```

```
/usr/local/lib/python3.8/dist-
packages/keras/optimizers/optimizer_v2/gradient_descent.py:108: UserWarning: The
`lr` argument is deprecated, use `learning_rate` instead.
    super(SGD, self).__init__(name, **kwargs)
```

## 2 Part A

i. Train data: 70%, Test data: 15%, Validation data: 15%

ii. Table 1. Architecture of model

```
[17]: data = [{"conv2d", 32, (3,3), "relu"}, {"batch_normalization", "", "", ""}, {"conv2d_1", 32, (3,3), "relu"}, {"batch_normalization_1", "", "", ""}, {"max_pooling2d", "", (2,2), ""}, {"dropout", 0.2, "", ""}, {"conv2d_2", 64, (3,3), "relu"}, {"batch_normalization_2", "", "", ""}, {"conv2d_3", 64, (3,3), "relu"}, {"batch_normalization_3", "", "", ""}, {"max_pooling2d_1", "", (2,2), ""}, {"dropout_1", 0.3, "", ""}, {"conv2d_4", 128, (3,3), "relu"}, {"batch_normalization_4", "", "", ""}, {"conv2d_5", 128, (3,3), "relu"}, {"max_pooling2d_2", "", (2,2), ""}, {"dropout_2", 0.4, "", ""}, {"flatten", "", "", ""}, {"dense", 128, "", "relu"}, {"batch_normalization_6", "", "", ""}, {"dropout_3", 0.5, "", ""}, {"dense_1", 10, "", "softmax"}]

col_names = ["layers", "number of neurons", "kernel", "activation function"]
print(tabulate(data, headers=col_names))
```

layers	number of neurons	kernel	activation function
conv2d	32	(3, 3)	relu
batch_normalization			
conv2d_1	32	(3, 3)	relu
batch_normalization_1			
max_pooling2d		(2, 2)	
dropout	0.2		
conv2d_2	64	(3, 3)	relu
batch_normalization_2			
conv2d_3	64	(3, 3)	relu
batch_normalization_3			
max_pooling2d_1		(2, 2)	
dropout_1	0.3		
conv2d_4	128	(3, 3)	relu
batch_normalization_4			
conv2d_5	128	(3, 3)	relu
batch_normalization_5			
max_pooling2d_2		(2, 2)	
dropout_2	0.4		
flatten			
dense	128		relu
batch_normalization_6			
dropout_3	0.5		
dense_1	10		softmax

a: Output layer:

Activation function: Softmax. Because SoftMax outputs its probability for each class, and it is the most appropriate function of the activation function.

Number of neurons: 10. Because there are 10 classes.

Cost function: categorical\_crossentropy. categorical\_crossentropy is a cost function used for classification and other functions do not perform well.

Learning rate:0.001.

Optimizer: SGD.

### 3 Part B

```
[11]: callback = tf.keras.callbacks.EarlyStopping(monitor='val_accuracy', patience=3,  
→restore_best_weights=True)
```

```
[12]: model.compile(optimizer=opt, loss='categorical_crossentropy', metrics=['accuracy'])
```

```
[13]: model_history = model.fit(X_train, y_train_onehot, epochs=100, batch_size = 32,  
→validation_data=(X_val, y_val_onehot), callbacks = [callback])
```

### 4 Part C

```
[14]: plot(model_history.history)
```




Figure 1: Loss plot for training and validation data in each epoch




Figure 2: Accuracy plot for training and validation data in each epoch

```
[15]: import seaborn as sns
predict_x=model.predict(X_test_normal)
predictions=np.argmax(predict_x,axis=1)

plt.figure(figsize=(10,8))
conf_mat = confusion_matrix(predictions.tolist(), y_test.tolist())
sns.heatmap(conf_mat, annot=True, cmap='crest')
plt.title('Confusion Matrix')
```

313/313 [=====] - 1s 3ms/step

```
[15]: Text(0.5, 1.0, 'Confusion Matrix')
```




Figure 3: Confusion matrix



## 5 Question 8

```
[7]: import numpy as np
import pandas as pd
import scipy.stats as st
import matplotlib.pyplot as plt
import seaborn as sns
```

```
[12]: N = 1000
np.random.seed(1)
X = np.concatenate((np.random.normal(0, 1, int(0.3 * N)), np.random.normal(5, 1,
→int(0.7 * N))))[:, np.newaxis]
```

### i. Real distribution

```
[13]: sns.distplot(X, bins = 100)
```

/usr/local/lib/python3.8/dist-packages/seaborn/distributions.py:2619:  
FutureWarning: `distplot` is a deprecated function and will be removed in a  
future version. Please adapt your code to use either `displot` (a figure-level  
function with similar flexibility) or `histplot` (an axes-level function for  
histograms).  
warnings.warn(msg, FutureWarning)

```
[13]: <matplotlib.axes._subplots.AxesSubplot at 0x7f6d4ad8d640>
```




Figure 4: Real distribution

```
[4]: class Parzen:
      data = []
      h = 1
      def __init__(self, data: list = []):
          self.data = data

      def set_window_size(self, h):
          self.h = h

      def get_dist(self, x):
          after_kernel = lambda i: st.norm.pdf((x-i)/self.h)
          kernelized = map(after_kernel, self.data)
          return sum(kernelized)/len(self.data)
```

**Window = 10**

```
[ ]: parzen_model = Parzen(X)
      x = np.linspace(-1, max(X), 1000)
      y = parzen_model.get_dist(x)
      parzen_model.set_window_size(10)
      plt.plot(x, parzen_model.get_dist(x))
```

```
[ ]: [<matplotlib.lines.Line2D at 0x7f5aacfb64f0>]
```




Figure 5: Data distribution plot with window = 10

**Window = 1**

```
[ ]: parzen_model.set_window_size(1)  
plt.plot(x,parzen_model.get_dist(x))
```

```
[ ]: [<matplotlib.lines.Line2D at 0x7f5aacf08310>]
```




Figure 6: Data distribution plot with window = 1

Window = 0.1

```
[ ]: parzen_model.set_window_size(0.1)
plt.plot(x,parzen_model.get_dist(x))
```

```
[ ]: [<matplotlib.lines.Line2D at 0x7f5aacedbcd0>]
```




Figure 7: Data distribution plot with window = 0.1

## 6 Conclusion

When the window size is equal to 10, the model suffers from underfitting, and if it is equal to 0.1, it also pays attention to the data noise and suffers from overfitting. It performs the best fit when the window size is equal to one.